操作系统大作业1实验报告

智能工程学院 自动化 1 班 黄舒怡 17364029

〇、 GitHub 上传情况

一共上传了 6 个代码,在所要求的的基础上多增加了 unlink.c。此代码于第二题 ——生产者消费者问题中使用,其作用为删掉创建的共享内存以及有名信号量。具体代码见第二题部分。

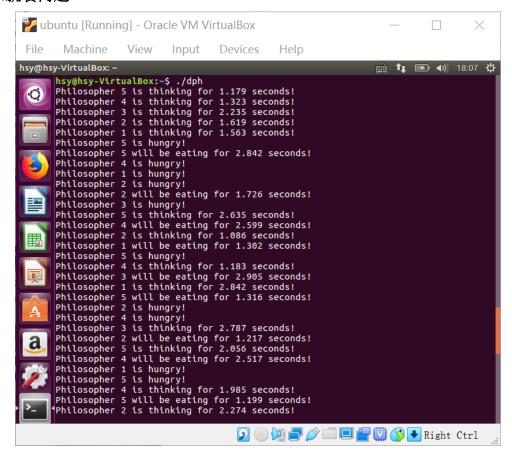
■ Makefile	100分的Makefile
cons.c 4	不能再高的prod和cons
dph.c 2	满分的dph
mycall.c 6	压轴出场的mycall
prod.c 3	不能再高的prod和cons
unlink.c 5	很有用的unlink

其中,Makefile 中包含 3 种命令,分别为 make all (同时产生上述文件对应的可执行文件)、make (产生单独的 bin 文件)、make clean (删除已生成的可执行文件)。 其代码如下:

运行情况示例如下:

```
hsy@hsy-VirtualBox:-$ ls
cons.c examples.desktop mycall prod.c 公共的 视频 文档 音乐
dph.c Makefile mycall.c unlink.c 模板 图片 下载 桌面
hsy@hsy-VirtualBox:-$ make
Please input like 'make dph' |
hsy@hsy-VirtualBox:-$ ls
cons.c dph.c Makefile mycall.c unlink.c 模板 图片 下载 桌面
dph examples.desktop mycall prod.c 公共的 视频 文档 音乐
hsy@hsy-VirtualBox:-$ make all
prod.c: In function 'producer':
prod.c:45:9: warning: format '%d' expects argument of type 'int', but argument 3
has type 'long int' [-Wformat=]
printf("Produce: pid = %d, tid = %d, data = %d\n", getpid(), syscall(SYS_getti
cons.c: In function 'consumer':
cons.c: Ad:9: warning: format '%d' expects argument of type 'int', but argument 3
has type 'long int' [-Wformat=]
printf("Consume: pid = %d, tid = %d, data = %d\n", getpid(), syscall(SYS_getti
hsy@hsy-VirtualBox:-$ ls
cons dph.c mycall prod.c 公共的 图片
cons.c examples.desktop mycall.c unlink 模板 文档
dph Makefile prod unlink 模板
```

一、 哲学家就餐问题

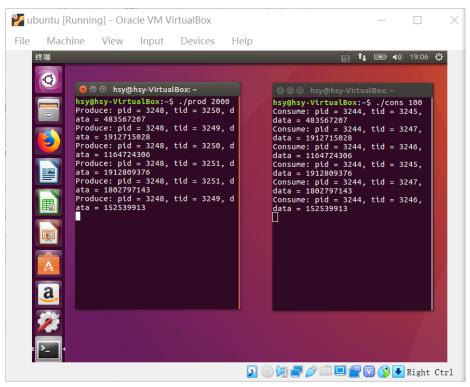


```
Philosopher 3 is hungry!
Philosopher 3 will be eating for 2.155 seconds!
Philosopher 5 is thinking for 1.924 seconds!
Philosopher 1 will be eating for 1.729 seconds!
Philosopher 4 is hungry!
Philosopher 5 is hungry!
Philosopher 5 is hungry!
Philosopher 6 is thinking for 2.076 seconds!
Philosopher 7 is thinking for 2.067 seconds!
Philosopher 8 is thinking for 1.931 seconds!
Philosopher 9 will be eating for 1.399 seconds!
Philosopher 1 will be eating for 1.399 seconds!
Philosopher 2 will be eating for 1.617 seconds!
Philosopher 4 will be eating for 1.617 seconds!
Philosopher 1 is hungry!
Philosopher 1 will be eating for 2.107 seconds!
Philosopher 1 will be eating for 2.107 seconds!
Philosopher 3 is hungry!
Philosopher 4 is thinking for 2.852 seconds!
Philosopher 5 will be eating for 2.550 seconds!
Philosopher 6 is thinking for 2.670 seconds!
Philosopher 7 is thinking for 2.670 seconds!
Philosopher 8 is thinking for 2.664 seconds!
Philosopher 9 is thinking for 2.668 seconds!
Philosopher 1 is hungry!
Philosopher 2 will be eating for 2.666 seconds!
Philosopher 1 is hungry!
Philosopher 2 will be eating for 2.666 seconds!
Philosopher 4 will be eating for 2.666 seconds!
Philosopher 1 is hungry!
Philosopher 2 will be eating for 2.666 seconds!
Philosopher 1 is hungry!
Philosopher 1 is hungry!
Philosopher 2 is thinking for 2.960 seconds!
Philosopher 1 will be eating for 1.181 seconds!
Philosopher 1 will be eating for 1.971 seconds!
Philosopher 3 is hungry!
```

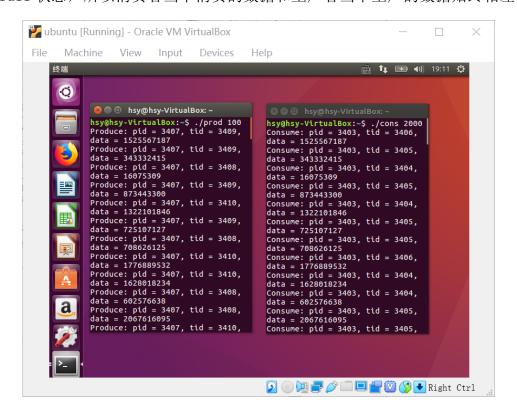
```
Philosopher 3 will be eating for 2.802 seconds!
Philosopher 4 is hungry!
Philosopher 1 is thinking for 1.497 seconds!
Philosopher 2 is hungry!
Philosopher 3 is thinking for 2.110 seconds!
Philosopher 4 will be eating for 1.372 seconds!
Philosopher 2 will be eating for 2.553 seconds!
Philosopher 1 is hungry!
Philosopher 4 is thinking for 1.627 seconds!
Philosopher 2 is thinking for 2.357 seconds!
Philosopher 1 will be eating for 1.104 seconds!
Philosopher 3 is hungry!
Philosopher 3 will be eating for 1.253 seconds!
Philosopher 1 is thinking for 1.513 seconds!
Philosopher 3 is thinking for 2.028 seconds!
```

二、 生产者消费者问题

1. λ p=2000, λ c=100; 消费者的消费速度远大于生产者的生产速度——生产者每生成一个数据,就立刻被消费者消费,缓冲区始终为 empty 状态。



2. λ p=100, λ c=2000; 生产者的生产速度远大于消费者的消费速度——缓冲区始终为 full 状态, 所以消费者当下消费的数据和生产者当下生产的数据始终相差 20 个。



```
🛑 🗊 hsy@hsy-VirtualBox: ~
Produce: pid = 3407, tid = 3410,
data = 371334813
Produce: pid = 3407, tid = 3409,
                                                                                    Consume: pid = 3403, tid = 3406,
data = 439250134
                                                                                    Consume: pid = 3403, tid = 3404,
data = 31595378
data = 280900240
Produce: pid = 3407, tid = 3408,
data = 1845823272
                                                                                   Consume: pid = 3403, tid = 3406,
data = 557839498
Consume: pid = 3403, tid = 3404,
data = 1485103186
Produce: pid = 3407, tid = 3410,
data = 1733050315
Produce: pid = 3407, tid = 3409,
data = 1274289499
                                                                                   Gata = 1463103186

Consume: pid = 3403, tid = 3404,

data = 864872343

Consume: pid = 3403, tid = 3406,

data = 995473402

Consume: pid = 3403, tid = 3404,

data = 1757974264
 Produce: pid = 3407, tid = 3408,
data = 221633292
Produce: pid = 3407, tid = 3410,
data = 2122460924
Produce: pid = 3407, tid = 3409,
data = 40017244
Produce: pid = 3407, tid = 3408,
                                                                                    Consume: pid = 3403, tid = 3405,
data = 281976
                                                                                   data = 281976

Consume: pid = 3403, tid = 3404,

data = 764797543

Consume: pid = 3403, tid = 3405,

data = 2060432198

Consume: pid = 3403, tid = 3404,

data = 1773287530
data = 2007115687
Produce: pid = 3407, tid = 3410,
data = 525759440
Produce: pid = 3407, tid = 3409,
data = 730589609
 hsy@hsy-VirtualBox:~$
                                                                                   hsy@hsy-VirtualBox:~$
```

```
Produce: pid = 3407, tid = 3408, data = 439250134
Produce: pid = 3407, tid = 3410, data = 31595378
Produce: pid = 3407, tid = 3409, data = 31595378
Produce: pid = 3407, tid = 3409, data = 157839498
Produce: pid = 3407, tid = 3408, data = 1485103186
Produce: pid = 3407, tid = 3409, data = 995473402
Produce: pid = 3407, tid = 3409, data = 995473402
Produce: pid = 3407, tid = 3409, data = 281976
Produce: pid = 3407, tid = 3409, data = 281976
Produce: pid = 3407, tid = 3408, data = 2806432198
Produce: pid = 3407, tid = 3408, data = 2606432198
Produce: pid = 3407, tid = 3409, data = 353756970
Produce: pid = 3407, tid = 3409, data = 353756970
Produce: pid = 3407, tid = 3409, data = 173287530
Produce: pid = 3407, tid = 3409, data = 1295514114
Produce: pid = 3407, tid = 3408, data = 1234179013
Produce: pid = 3407, tid = 3408, data = 114594618
Produce: pid = 3407, tid = 3408, data = 114594618
Produce: pid = 3407, tid = 3408, data = 2088653303
Produce: pid = 3407, tid = 3408, data = 20751525967
Produce: pid = 3407, tid = 3408, data = 20751525967
Produce: pid = 3407, tid = 3408, data = 860225859
Produce: pid = 3407, tid = 3408, data = 860225859
Produce: pid = 3407, tid = 3409, data = 173308313
Produce: pid = 3407, tid = 3409, data = 1848823272
Produce: pid = 3407, tid = 3409, data = 1848823272
Produce: pid = 3407, tid = 3408, data = 1848823272
Produce: pid = 3407, tid = 3408, data = 1848823272
Produce: pid = 3407, tid = 3408, data = 1848823272
Produce: pid = 3407, tid = 3408, data = 1848823272
Produce: pid = 3407, tid = 3408, data = 1848823272
Produce: pid = 3407, tid = 3408, data = 1848823272
Produce: pid = 3407, tid = 3408, data = 1848823272
Produce: pid = 3407, tid = 3408, data = 1848823272
Produce: pid = 3407, tid = 3408, data = 221633292
Produce: pid = 3407, tid = 3408, data = 221633292
Produce: pid = 3407, tid = 3408, data = 207115687
Produce: pid = 3407, tid = 3408, data = 207115687
Produce: pid = 3407, tid = 3409, data = 1574889499
Produce: pid = 3407, tid = 3409, data = 2206900240
Produce: pid = 3407, tid = 3409,
```

3. λ p=3000, λ c=3000; 无明显规律。

```
hsy@hsy-VirtualBox:-
hsy@hsy.VirtualBox:-
hsy@hsy.V
```

```
data = 1558200475
Produce: pid = 3592, tid = 3594, data = 1477825023
Produce: pid = 3592, tid = 3595, data = 416502274
Produce: pid = 3592, tid = 3595, data = 416502274
Produce: pid = 3592, tid = 3595, data = 48507473
Produce: pid = 3592, tid = 3595, data = 48507473
Produce: pid = 3592, tid = 3594, data = 52174386
Consume: pid = 3587, tid = 3588, data = 1525788137
Produce: pid = 3592, tid = 3594, data = 1984339213
Produce: pid = 3592, tid = 3593, data = 1984339213
Produce: pid = 3592, tid = 3593, data = 281650427
Produce: pid = 3592, tid = 3593, data = 2416502274
Produce: pid = 3592, tid = 3593, data = 12861953621
Consume: pid = 3587, tid = 3590, data = 1728901263
Consume: pid = 3587, tid = 3590, data = 1616502274
Consume: pid = 3587, tid = 3590, data = 416502274
Consume: pid = 3587, tid = 3590, data = 161502274
Consume: pid = 3587, tid = 3590, data = 1616502274
Consume: pid = 3587, tid = 3590, data = 1616502274
Consume: pid = 3587, tid = 3590, data = 1616502274
Consume: pid = 3587, tid = 3590, data = 1616502274
Consume: pid = 3587, tid = 3590, data = 1616502274
Consume: pid = 3587, tid = 3590, data = 1616502274
Consume: pid = 3587, tid = 3590, data = 1616502274
Consume: pid = 3587, tid = 3590, data = 1616502274
Consume: pid = 3587, tid = 3590, data = 1616502274
Consume: pid = 3587, tid = 3590, data = 416502274
Consume: pid = 3587, tid = 3590, data = 416502274
Consume: pid = 3587, tid = 3590, data = 416502274
Consume: pid = 3587, tid = 3590, data = 416502274
Consume: pid = 3587, tid = 3590, data = 416502274
Consume: pid = 3587, tid = 3590, data = 416502274
Consume: pid = 3587, tid = 3590, data = 416502274
Consume: pid = 3587, tid = 3590, data = 416502274
Consume: pid = 3587, tid = 3590, data = 416502274
Consume: pid = 3587, tid = 3590, data = 416502274
Consume: pid = 3587, tid = 3590, data = 416502274
Consume: pid = 3587, tid = 3590, data = 416502274
Consume: pid = 3587, tid = 3590, data = 416502274
Consume: pid = 3587, tid = 3590, data = 416502274
Consume: pid = 3587, tid = 3590, data = 416502274
Consume: pid
```

4. unlink.c

```
#include <semaphore.h>

int main() {
    sem_unlink("/INIT");
    sem_unlink("/FULL");
    sem_unlink("/EMPTY");
    return 0;
}
```

unlink 的作用:每次运行 prod 和 cons 前运行 unlink, 删掉已创建的共享内存和有名信号量, 防止历史数据对新一次的运行造成影响。

所以,unlink 是有用的!

三、 Linux 内核实验

a) complete fair scheduler (CFS) 内核代码阅读报告

1 Linux 进程的基本结构

Linux 内核使用 task_struct 结构体描述进程,该结构体定义在<include/linux/sched.h>中。task_struct 结构体是一个类似于 PCB 的结构,其中保存了进程的大量基本信息,主要内容大致可分为以下几类:

1.1 进程基本属性

进程状态 state: 进程的状态码, 其二进制的每位代表一个不同的状态。状态码分运行状态和退出状态两部分, 对应位置为1时即标识进程处于该状态。

引用次数 usage:结构体的被引用次数。只有当该变量为 0 时,结构体才能被销毁。

进程标识符 pid: 进程的唯一编号。

线程组标识符 tgid: 线程组的所有者编号,即其所属进程的唯一编号。由于在 Linux 内核中,线程也被实现为一个进程(轻量级进程),即也拥有一个 task_struct 结构体。因此,当该结构体标识一个进程时,tgid 即为进程编号 pid;结构体标识一个线程时,tgid 为拥有该线程的进程编号。

1.2 进程间关系

```
struct task_struct __rcu *real_parent; /* real parent process */
struct task_struct __rcu *parent; /* recipient of SIGCHLD, wait4() reports */
/*
    * children/sibling forms the list of my natural children
    */
struct list_head children; /* list of my children */
struct list_head sibling; /* linkage in my parent's children list */
struct task_struct *group_leader; /* threadgroup leader */
```

父进程 parent: 进程的父进程。

真实父进程 real_parent: 进程当前的父进程。在一些特殊情况下,进程当前的父进

程可能并非其原始父进程,例如 gdb 调试某程序时,其 real_parent 会被设置为 gdb 进程,而其 parent 的值并不一定。

子进程列表 children: 维护其子进程的双向链表,便于对其子进程进行遍历操作。

兄弟进程列表 sibling: 维护其兄弟进程(拥有同一个父进程的进程集合)的双向链表,便于进行遍历操作。

组代表 group_leader: 即 tgid 标识的进程编号对应的 task_struct 结构体。若当前结构体 this 标识一个线程,那么通过 this->group leader 可以访问拥有这个线程的进程。

1.3 调度参数

int prio, static_prio, normal_prio;
unsigned int rt_priority;
const struct sched_class *sched_class;
struct sched_entity se;
struct sched_rt_entity rt;
unsigned int policy;
int nr_cpus_allowed;
cpumask t cpus allowed;

优先级 prio、静态优先级 static_prio、常规优先级 normal_prio: 调度时可能使用的各种优先级信息。prio 为进程的动态优先级,一方面通过其取值范围可以区分进程类型(0~99 为实时进程,100~139 为普通进程),另一方面,其值越小,代表进程优先级越高,宏观上看更"容易"被调度到。static_prio 是自父进程继承的优先级,用于计算进程的初始时间片长度与动态优先级。normal_prio 是进程"应有"的动态优先级,某些时候,进程的动态优先级可能被暂时提升,提升过后应当恢复到的优先级即为 normal_prio。

实时进程优先级 rt priority: 实时进程的优先级。

调度类 sched_class: 进程所使用的调度类。

调度实体 sched entity: 进程所属的调度实体。

实时调度实体 sched rt entity: 进程所属的实时调度实体。

调度策略 policy: 进程使用的调度策略(抢占式/非抢占式)。

可用 cpu 数 nr_cpus_allowed: 指明该进程可在多少个 cpu 上进行调度。

可用 cpu 掩码 cpus_allowed: 指明该进程可在哪些 cpu 上进行调度。

1.4 文件和内存指针

```
struct mm_struct *mm, *active_mm;
/* filesystem information */
struct fs_struct *fs;
/* open file information */
struct files_struct *files;
```

地址空间 mm, 活跃地址空间 active_mm: 分别指向进程地址空间和最近使用过的地址空间 (利用时间局部性)。

文件系统指针 fs: 指向文件系统的信息结构体。

文件指针 files: 己打开的文件指针。

1.5 信号

```
struct signal_struct *signal;
struct sighand_struct *sighand;
```

sigset_t saved_sigmask; /* restored if set_restore_sigmask() was used */
struct sigpending;

信号描述符 signal: 指向进程信号结构体的指针。

信号处理器 sighand: 指向进程信号处理器的指针。

信号掩码 sigmask: 表示进程可以接收到的信号。其二进制表示的每一位代表一个不同信号的接收使能,置 0 表示可以接收,置 1 表示不能接收。

挂起信号 pending: 保存所有已经接收但还未处理的信号。

1.6 其它

task_struct 结构体除了上述成员之外,还有非常多的其它成员,包括 trace 相关的成员、NUMA 相关的成员等。由于这些成员在以下部分不为重点(以及笔者对这些并不了解),故不再对它们做更多介绍。

2 进程的组织结构

为了对进程进行有效的管理,Linux 系统将进程组织成几种数据结构,便于应对不同的操作。以下对有代表性的进程组织结构进行介绍:

2.1 双向链表

在 task_struct 结构体中有成员 struct list_head tasks,该成员为一双向链表的节点。Linux 系统将所有进程用一个双向链表连接,并定义了一个宏 for_each_process:

```
#define for_each_process(p) \
    for (p = &init_task; (p = next_task(p)) != &init_task; )
```

其中 init_task 为链表头节点。追踪其初始化过程,发现这个节点的初始化在 init_task.c 中最终完成。经过一系列曲折的探索与发现,可以找到其中初始化 pid 的数据路径为: INIT_TASK()->INIT_PID_LINK()->init_struct_pid->INIT_STRUCT_PID->ATOMIC_INIT(1)。 2.2 散列表

有一些操作是通过进程号进行的(比如 kill pid 结束进程),因此我们还需要一个能快速将进程号转换成 task_struct 结构体地址的方法。在 Linux 中,进程以 pid 为关键词,通过散列函数组织成散列表,使用开散列方式解决冲突。当需要通过 pid 快速定位进程时,先通过散列函数获取 pid 对应的散列表下标,然后遍历放在该下标的开链表,即可快速定位进程。

```
/* PID/PID hash table linkage. */
```

struct pid_link pids[PIDTYPE_MAX];

在 task_struct 结构体中, pids 即为一个散列表的入口, 其中 struct pid_link 包含两个成员: hlist_node 与 pid 结构体, 前者为散列表的开链表节点, 后者为该节点保存的 pid 值。

3 进程状态设置

```
#define TASK RUNNING
                             0
#define TASK INTERRUPTIBLE 1
#define TASK UNINTERRUPTIBLE
                                  2
#define __TASK_STOPPED
                             8
#define __TASK_TRACED
/* in tsk->exit state */
#define EXIT DEAD
                        16
#define EXIT_ZOMBIE
                        32
#define EXIT_TRACE
                        (EXIT_ZOMBIE | EXIT_DEAD)
/* in tsk->state again */
#define TASK DEAD
                         64
#define TASK_WAKEKILL
                              128
#define TASK WAKING
                         256
#define TASK PARKED
                         512
#define TASK_NOLOAD
                         1024
```

```
#define __set_task_state(tsk, state_value)
    do {
        (tsk)->task_state_change = _THIS_IP_;
        (tsk)->state = (state_value);
    } while (0)

#define set_task_state(tsk, state_value)
    do {
        (tsk)->task_state_change = _THIS_IP_;
        smp_store_mb((tsk)->state, (state_value));
    } while (0)
```

在<include/linux/sched.h>中定义了进程的合法状态,其中数值较小的几个状态和熟知的 Linux 状态模型基本相符。此外,文件中还定义了设置进程状态的宏,通过搜索该宏的调用时机发现,内核代码大部分时候只会在将进程设置为 TASK_UNINTERRUPTIBLE 状态时才调用该宏,其余时候均直接使用赋值语句改变进程状态。

4 Linux 的调度架构

4.1 从调度时机到调度器架构

4.1.1 调度函数

通过课上的学习,我们大约知道调度程序何时工作。

• 在 3(b)中做了这样一个实验:启动一个进程,在一个循环 10000 次的结构中调用 usleep(1),然后调用新添加的系统调用查看进程信息,发现 usleep()会引发一次**非抢占** 式 的 上 下 文 切 换 。搜 索 发 现 usleep 调 用 了 内 核 中 的 nanosleep,在 中找到了函数 do_nanosleep()中的上下文切换部分:

set_current_state(TASK_INTERRUPTIBLE);

```
if (likely(t->task))
    freezable_schedule();
```

进一步查看 freezable_schedule 函数,发现其中主要调用了<kernel/sched/core.c>中的 schedule 函数,这是 Linux 调度器的主要函数之一。

在 3(b) 中还做了这样一个实验: 启动一个进程, 在循环 10 亿次的结构中累加一个变量, 然后调用新添加的系统调用查看进程信息, 发现进程被数次**抢占式**切换上下文。在 sourceinsight 中搜索关键词 schedule, 在 core. c 中发现了函数 scheduler tick。按照

注释,这个函数由系统时钟定时触发,检查是否需要进行调度。

4.1.2 调度类

```
在 scheduler_tick 函数中有这样一条语句:
curr->sched_class->task_tick(rq, curr, 0);
```

而在schedule函数中,同样通过多层函数调用,最终调用了curr->sched_class成员中的dequeue_task函数。因此可以推断:在Linux系统中,调度器设计为两层结构,其中schedule和scheduler_tick两个调度程序负责进行CPU的上下文切换,而sched_class类中的成员函数负责进行进程的选择并维护调度需要的数据结构。

因此,Linux内核代码还应在别处实现了具体的调度类以及各种成员函数。在搜索中发现了在〈kernel/sched/fair.c〉中定义的fair_sched_class调度类,我们又回到了最初的起点。

5 CFS 调度算法

5.1 思路

CFS 调度算法和 RR 调度算法有一定的类似。RR 期望在一个调度周期内所有被调度的进程轮流运行且时间相同,而 CFS 期望在一个调度周期内所有被调度的**实体按某种策略运行且虚拟运行时间相同**。它以 nice 值为依据设置不同进程的运行时间权重,通过实际运行时间和权重的综合计算得出虚拟运行时间,权重越大,虚拟运行时间就走得越"慢"。因此,若所有调度实体的虚拟运行时间相同,那么权重大的进程的实际运行时间就更长。

以下先介绍 CFS 调度算法的主要结构体,再介绍调度算法的主要流程和策略。

5.2 CFS 调度算法使用的主要结构

5.2.1 调度实体

```
struct rb_node
                         run_node;
    struct list head
                        group_node;
    unsigned int
                         on_rq;
    u64
                  vruntime;
#ifdef CONFIG_FAIR_GROUP_SCHED
    struct sched_entity *parent;
    /* rq on which this entity is (to be) queued: */
                        *cfs_rq;
    struct cfs_rq
    /* rq "owned" by this entity/group: */
                        *my_q;
    struct cfs_rq
#endif
};
```

在CFS调度算法中,被调度的单位为调度实体,可以是一个进程,也可以是一组进程。各实体的虚拟运行时间相同,说的是实体内所有进程的总虚拟运行时间相同。

5.2.2 就绪队列

```
/* CFS-related fields in a runqueue */
      struct cfs_rq {
          struct load_weight load;
          u64 exec clock;
          u64 min vruntime;
      #ifndef CONFIG 64BIT
          u64 min_vruntime_copy;
      #endif
          struct rb_root tasks_timeline;
          struct rb_node *rb_leftmost;
          struct sched_entity *curr, *next, *last, *skip;
      #endif /* CONFIG FAIR GROUP SCHED */
      #endif /* CONFIG_SMP */
      #ifdef CONFIG_FAIR_GROUP_SCHED
          struct rq *rq; /* cpu runqueue to which this cfs_rq is attached */
          struct task_group *tg; /* group that "owns" this runqueue */
      #endif /* CONFIG FAIR GROUP SCHED */
      };
```

只有在就绪队列中的实体才可能被调度。就绪队列是一个优先队列,其内部使用了红 黑树的数据结构,可以高效进行增删改查的操作。

5.3 CFS 调度算法的主要流程

```
static struct task_struct *
    pick_next_task_fair(struct rq *rq, struct task_struct *prev)
         struct cfs_rq *cfs_rq = &rq->cfs;
         struct sched_entity *se;
         struct task_struct *p;
         cfs_rq = &rq -> cfs;
         put_prev_task(rq, prev);
         do {
              se = pick_next_entity(cfs_rq, NULL);
              set next entity(cfs rq, se);
              cfs_rq = group_cfs_rq(se);
         } while (cfs_rq);
         p = task\_of(se);
         if (hrtick_enabled(rq))
              hrtick_start_fair(rq, p);
         return p;
    }
```

我们知道:在调度算法中,选择换入的进程是最重要的部分之一。事实上,CFS 选择换入进程的方式一目了然:从就绪队列中选取虚拟运行时间最小的节点,若该节点为一个进程组,那么继续从该进程组的就绪队列中选取虚拟运行时间最小的节点。递归进行这一操作,直到选择的调度实体为一个进程。

5.4 Q & A

5.4.1 简述进程优先级、nice 值和权重之间的关系

进程优先级是内核用来表示进程执行迫切性的数值,其中 0~99 代表实时进程, 100~139 代表普通进程。

nice 值范围在-20~+19 之间,每次进入调度序列时被设置,直接加在进程优先级上,用于修正进程的优先级,是一个形象的命名,表示一个进程"谦让"的程度。nice 值越高,进程在该次运行的优先级就越低,也就是更"谦让"。

权重是对应 nice 值的,实际运行时间到虚拟运行时间的转化比例。在 Linux 系统中,转化表设置在 prio to weight 中:

```
static const int prio_to_weight[40] = {
               88761,
                           71755,
                                        56483,
                                                   46273,
 /* -20 */
                                                               36291,
 .
/* -15 */
                29154,
                           23254,
                                        18705,
                                                   14949,
                                                               11916,
                 9548,
                             7620,
 /* -10 */
                                        6100,
                                                    4904,
                                                                3906,
                             2501,
                                                    1586,
   -5 */
                 3121,
                                                                1277,
                                        1991,
     0 */
                                         655,
                                                                 423,
                 1024,
                              820,
                                                     526,
                  335,
                                         215,
                                                     172,
                                                                 137,
                              272,
     5 */
    10 */
                  110,
                               87,
                                           70,
                                                      56,
                               29,
     15 */
                   36,
                                                      18,
                                           23,
                                                                  15,
```

相邻两级的权重差距都约为25%。

5.4.2 vruntime 的基本思想是什么

}

正如上面所说,CFS 希望 nice 值高的实体获得更高的实际运行时间比例,因此将实际运行时间乘一个权重比例,转化成虚拟运行时间 vruntime。平衡各实体的 vruntime,实际上就平衡了各实体的加权运行时间,那么 nice 值高的实体就获得了更高的实际运行比例。

5.4.3 vruntime 是如何计算的,何时得到更新

同样如上面所说,vruntime的计算方法即为实际运行时间乘一个权重比例,它的计算函数在<kernel/sched/fair.c>中:

```
static u64 __calc_delta(u64 delta_exec, unsigned long weight, struct load_weight *lw)
{
    u64 fact = scale_load_down(weight);
    int shift = WMULT_SHIFT;

    __update_inv_weight(lw);

    if (unlikely(fact >> 32)) {
        while (fact >> 32) {
            fact >>= 1;
            shift--;
        }
    }

/* hint to use a 32x32->64 mul */
    fact = (u64)(u32)fact * lw->inv_weight;

while (fact >> 32) {
        fact >>= 1;
        shift--;
        shift--;
    }
```

return mul_u64_u32_shr(delta_exec, fact, shift);

计算公式为: vruntime=time*NICE_0_LOAD/load, 其中 NICE_0_LOAD 为 nice 值为 0 的时候对应的权重(即 1024)。由于除法运算速度慢,这里预先计算了 2³²/prio_to_weight 的值 prio_to_wmult,这样所有运算都变成了乘法和位移操作,可以快速完成。

更新 vruntime 的函数是 fair.c 的 update_curr 函数,它通过计算时间增量来计算 vruntime 的增量。在进程创建、进出调度队列、周期调度器调度的时候,这个函数都会被调用。

5.4.4 min_vruntime 有什么作用

}

min_vruntime 是 CFS 调度队列中 vruntime 的最小值。一个新创建的进程进入队列,或是睡眠一段时间后刚被唤醒时,它的 vruntime 和一直就绪的进程相比会有一定的落后,若此时维持 vruntime 值不变,那么这个进程就会一直被调度,影响公平性。因此,这些情况发生时,进程的 vruntime 会进行适当的调整,例如进程创建时,调度类的 task_fork_fair 函数会调用 place_entity 函数,将 vruntime 先设为min_vruntime,再在这个基础上进行适当的调整。在下面的实验中,我们可以观察到:进程的总运行时间和虚拟运行时间存在一个几乎相等的差值,这一定程度上也印证了进程创建时将 vruntime 设为就绪队列的 min_vruntime 这一策略。

另外,在多核处理器中,还涉及到一个新的需要调节 vruntime 的场景,即任务迁移。当进程从一个核心迁移到另一个核心时,由于两个核心的 vruntime 分布可能不同,若进程从 vruntime 小的核心迁移到较大的核心,就可能占便宜。CFS 应对这个问题的思想是:进程移动时,保留其"相对 vruntime",具体做法是:进程离开队列时,减掉这个队列的 min_vruntime;进入队列时,加上这个队列的 min_vruntime,保留进程相对于一个队列的 vruntime,一定程度上保留了公平性。

b) 添加系统调用: 用户层测试程序 mycall.c

1. 运行 screenfetch

```
hsy@hsy-VirtualBox:~$ screenfetch
                                                        Ubuntu 16.04 xenial
nel: x86_64 Linux 4.16.1
ime: 1h 33m
                                                                 1785
                                                            bash 4.3.48
tion: 800x600
                                    +sssoo+/
                                                         Unity 7.4.5
                                     /sssooo.
                                                         Compiz
                                                                 Ambiance
                                                                  Ambiance [GTK2/3]
                                                                   ubuntu-mono-dark
                                                           Ubuntu 11
                                                          Intel Core i7-7500U CPU @ 2.904GHz
675MiB / 1993MiB
                                  .00++0
                                 ++000+++
                                 +00+++0\
```

2. 添加系统调用

```
syscall_64.tbl
             Æι
                                                                                 保存(S)
309
        common
                 getcpu
                                           sys getcpu
                 process_vm_readv
310
        64
                                           sys_process_vm_readv
311
        64
                 process_vm_writev
                                           sys_process_vm_writev
312
        common
                 kcmp
                                           sys kcmp
                 finit_module
sched_setattr
                                           sys_finit_module
sys_sched_setattr
313
        common
314
        common
315
        common
                 sched getattr
                                           sys sched getattr
                                           sys_renameat2
                 renameat2
316
        common
317
        common
                 seccomp
                                           sys_seccomp
318
        common
                 getrandom
                                           sys_getrandom
                 memfd_create
                                           sys_memfd_create
319
        common
                                           sys_kexec_file_load
320
        common
                 kexec_file_load
321
        common
                 bpf
                                           sys bpf
                                           sys_execveat/ptregs
322
        64
                 execveat
                 userfaultfd
323
        common
                                           sys_userfaultfd
324
        common
                 membarrier
                                           sys_membarrier
                                           sys_mlock2
        common
325
                 mlock2
                                           sys_copy_file_range
                 copy_file_range
326
        common
327
                 preadv2
                                           sys_preadv2
        64
                                           sys_pwritev2
                 pwritev2
328
        64
329
        common
                 pkey_mprotect
                                           sys_pkey_mprotect
330
        common
                 pkey_alloc
                                           sys_pkey_alloc
                                           sys_pkey_free
        common
                 pkey_free
331
332
        common
                 statx
                                           sys statx
333
                                           sys_print_msg
        64
                 print msg
```

```
syscalls.h
                 Ħ
   打开(O) ▼
                                                                                                保存(S)
                                    /usr/src/linux-4.16.1/arch/x86/include/asm
  * syscalls.h - Linux syscall interfaces (arch-specific)
  * Copyright (c) 2008 Jaswinder Singh Rajput
  * This file is released under the GPLv2.
  {}^{\star} See the file COPYING for more details.
 #ifndef _ASM_X86_SYSCALLS_H
#define _ASM_X86_SYSCALLS_H
 #include <linux/compiler.h>
 #include <linux/linkage.h>
 #include <linux/signal.h>
 #include <linux/types.h>
 /* Common in X86_32 and X86_64 */
 /* kernel/ioport.c */
asmlinkage long sys_ioperm(unsigned long, unsigned long, int);
asmlinkage long sys_iopl(unsigned int);
asmlinkage long sys_print_msg(void);
 /* kernel/ldt.c */
 asmlinkage long sys_modify_ldt(int, void __user *, unsigned long);
 /* kernel/signal.c */
 asmlinkage long sys_rt_sigreturn(void);
                                                  sys.c
                Ħ
                                                                                                保存(S)
  打开(O) ▼
                                         /usr/src/linux-4.16.1/kernel
          return 0;
}
asmlinkage long sys_print_msg(void){
#define PN(F)
          printk("%-45s:%14Ld.%06ld\n", #F, (long long)(p->F/1000000), (long)(p->F%
1000000))
#define P(F)
          printk("%-45s:%21Ld\n", #F, (long long)p->F)
          struct task_struct *p=current;
          PN(se.exec_start);
          PN(se.vruntime);
          PN(se.sum_exec_runtime);
          P(se.nr_migrations);
printk("%-45s:%21Ld\n", "nr_switches", (long long)(p->nvcsw+p->nivcsw));
printk("%-45s:%21Ld\n", "nr_voluntary_switches", (long long)p->nvcsw);
printk("%-45s:%21Ld\n", "nr_involuntary_switches", (long long)p->nivcsw);
          P(se.load.weight);
          P(se.avg.load_sum);
          P(se.avg.util sum);
          P(se.avg.load_avg);
          P(se.avg.util_avg);
          P(se.avg.last_update_time);
#undef PN
#undef P
```

return 1;

2.1 先启动一个进程, 在一个循环 10000 次的结构中调用 usleep(1)

```
#include <stdio.h>
#include <linux/kernel.h>
#include <linux/kernel.h>
#include <sys/syscall.h>
#include <unistd.h>

int main() {
    int i=0;
    for (i=0;i<=10000;i++)
        usleep(1);
    long a = syscall(333);
    printf("Syscall returns %d\n", a);
    return 0;
}
```

```
sy@hsy-VirtualBox:~$ ./mycall
yscall returns 1
sy@hsy-VirtualBox:~$ dmesg
  6808.029829] se.exec_start
6808.029830] se.vruntime
                                                                                                                                                                                  6808029.813021
                                                                                                                                                                                            146.735237
 6808.029830] se.vruntime
6808.029831] se.sum_exec_runtime
6808.029831] se.nr_migrations
6808.029832] nr_switches
6808.029833] nr_involuntary_switches
6808.029833] nr_involuntary_switches
6808.029834] se.load.weight
6808.029834] se.avg.load_sum
6808.029835] se.avg.util_sum
6808.029836] se.avg.util_avg
6808.029836] se.avg.util_avg
6808.029836] se.avg.last_update_time
                                                                                                                                                                                             108.715921
                                                                                                                                                                                                             9967
                                                                                                                                                                                                             9967
                                                                                                                                                                                                     1048576
                                                                                                                                                                                                            7844
                                                                                                                                                                                                     7724892
                                                                                                                                                                                                                171
                                                                                                                                                                                                                164
                                                                                                                                                                                     6808029812736
```

2.2 先启动一个进程,在循环 10 亿次的结构中累加一个变量

```
mycall.c
             .FR
 打开(O) ▼
#include <stdio.h>
#include <linux/kernel.h>
#include <sys/syscall.h>
#include <unistd.h>
int main() {
        int i=0;
        int j=0;
        for (i=0;i<=1000000000;i++)</pre>
                j++;
        long a = syscall(333);
        printf("Syscall returns %d\n", a);
        return 0;
}
```

```
-VirtualBox:~$ ./mycall
yscall returns 1
sy@hsy-VirtualBox:~$ dmesg
                                                           6648297.938901
                                                             2072.792164
                                                             2036.152403
                                                                     57
                                                                     0
                                                                     57
                                                                 1048576
                                                                  47727
                                                                48798244
                                                                   1023
                                                                   1022
 6648.301294] se.avg.last_update_time
                                                           6648297937920
```

2.3 在调用前不执行任何指令

```
#include <stdio.h>
#include <linux/kernel.h>
#include <sys/syscall.h>
#include <unistd.h>

int main() {
    long a = syscall(333);
    printf("Syscall returns %d\n", a);
    return 0;
}
```